



# 扩散式遗传-微粒群优化 算法及其应用

林 晨, 俞金寿

(华东理工大学 自动化研究所, 上海 200237)

**摘要:** 将 PSO 算法与 ScGA(扩散式遗传算法)相结合, 提出 ScGA-PSO 优化算法。通过对 4 种常用的测试函数进行优化和比较, 结果表明 ScGA-PSO 性能相比 PSO 有明显的提升, 且更容易找到最优解。然后将 ScGA-PSO 用于延迟焦化装置主分馏塔汽油干点软测量, 建立基于 ScGA-PSO 的粗汽油干点神经网络软测量模型, 通过与实际工业数据对比, 表明该模型精度高、性能好, 具有广阔的应用前景。

**关键词:** 微粒群优化算法; 扩散式遗传算法; 粗汽油干点值; 软测量

**中图分类号:** TP183

**文献标志码:** A

**文章编号:** 1007-7324(2009)01-0023-04

## ScGA-PSO Algorithm and Its Application

Lin Chen, Yu Jinshou

(Research Institute of Automation, East China University of  
Science and Technology, Shanghai, 200237, China)

**Abstract:** An improved particle swarm optimization algorithm — ScGA-PSO was proposed based on PSO and Scatter GA. Then ScGA-PSO and PSO were used to resolve four widely used test functions' optimization problems. Results show that ScGA-PSO's performance is much better than PSO's and ScGA-PSO can find the best fit easier. Next ScGA-PSO is applied to train artificial neural network to construct a practical soft-sensor of gasoline endpoint of main fractionator of delayed coking unit. The obtained results and comparison with actual industrial data indicate that the new method proposed by this paper is feasible and effective in soft-sensor of gasoline endpoint.

**Keywords:** particle swarm optimization algorithm; scatter GA; gasoline endpoint; soft-sensor

## 1 引言

微粒群优化算法 PSO (Particle Swarm Optimization Algorithm) 是 Kennedy 和 Eberhart 于 1995 年提出的进化计算算法<sup>[1-2]</sup>。PSO 简单且具有许多良好的优化性能, 是一种新兴的很有发展前途的全局优化算法, 已在许多领域得到应用; 但对一些复杂优化问题存在容易陷入局部极值的缺陷<sup>[3-4]</sup>。为了使 PSO 更容易逃脱局部极值、提高搜索效率和扩大应用范围, 文章将 PSO 与局部搜索能力很强的扩散式遗传算法 (Scatter GA, ScGA) 结合, 提出 ScGA-PSO 优化算法。

## 2 ScGA-PSO 优化算法

### 2.1 基本 PSO 优化算法

PSO 基于对鸟群社会行为模拟的演化算法。PSO 通过模拟鸟群捕食的行为来寻找全局最优解。当求解优化问题时, 问题的解就对应于搜索空间中一只鸟的位置, 即“粒子”, 每个粒子都有自己

的位置和速度。各个粒子记忆、追随当前的最优粒子, 并根据它自身的“经验”和相邻粒子群的最佳“经验”在解空间中向更好的位置“飞行”。

假设搜索区域为  $N$  维空间, 则第  $i$  个粒子的位置可以表示为  $x_i = (x_{i1}, x_{i2}, \dots, x_{id})$ , 速度可以表示为  $v_i = (v_{i1}, v_{i2}, \dots, v_{id})$ , 粒子根据方程(1)和(2)更新本身的速度和位置:

$$v_{id} = \chi[\omega v_{id} + c_1 r_1 (p_{id} - x_{id}) + c_2 r_2 (p_{gd} - x_{id})] \quad (1)$$

$$x_{id} = x_{id} + v_{id} \quad (2)$$

### 2.2 Scatter GA 优化算法

#### 2.2.1 算法描述

a) 随机产生一个包含  $N$  个个体的初始种群。

收稿日期: 2008-11-03。

作者简介: 林 晨(1984—), 男, 福建人, 华东理工大学自动化系在读硕士研究生, 主要研究方向是智能优化算法, 软测量建模。

b) 对初始种群进行适应度评价。

c) 找到最优个体,将其保存在种群的第  $N+1$  位。

d) 从前  $N$  个个体中顺序地取一个个体,如果它与第  $N+1$  位的个体的变量空间的距离或适应度空间的距离大于一定值,则进行交叉操作,以子代个体中适应度值较高的一个个体代替顺序取出的个体;否则,对顺序取出的个体以一个给定的概率进行变异(第 1 变异算子)。

e) 反复执行步骤 d),直到  $N$  个个体全部取到。

f) 对整个种群以一个较小的概率进行变异(第 2 变异算子)。

g) 对新种群进行适应度评价,找到最优个体。如果新最优个体优于原第  $N+1$  位个体则替换;否则,保留原个体。

h) 反复执行步骤 d)~g),直到满足终止准则。

## 2.2.2 算法特点<sup>[5]</sup>

a) 由于二进制编码和解码会带来精度和效率问题,因而,文中提出的算法采用实数编码。

b) 交叉只在个体之间的适应度空间距离或变量空间的距离大于一定值时进行,这可以保证种群的多样性,防止早熟收敛,交叉操作采用算术交叉方式。其方法为

$$\begin{cases} x_1' = \alpha \cdot x_1 + (1-\alpha) \cdot x_2 \\ x_2' = \alpha \cdot x_2 + (1-\alpha) \cdot x_1 \end{cases} \quad (3)$$

式中  $\alpha$ —— $0 \sim 1$  之间的随机数; $x_1, x_2$ ——算术交叉父代个体向量; $x_1', x_2'$ ——算术交叉子代个体向量。

另外,算法规定只对那些适应度空间或变量空间的距离大于给定值的个体进行交叉,变量空间内的距离定义为

$$d = \sqrt{\sum_{i=1}^n (x_1^i - x_2^i)^2} \quad (4)$$

式中  $x_1^i, x_2^i$ ——个体  $x_1, x_2$  的基因值。

适应值空间距离定义为适应值之差:

$$d = f(x_i) - f(x_j) \quad (5)$$

式中  $f$ ——适应度函数; $x_i, x_j$ ——个体向量。

这样便可避免对变量空间或适应度空间中相邻的个体进行交叉。其作用类似于交叉限制和小生态环境机制的作用,可以维持种群的多样性,使搜索更有可能接近全局最优值。文中采用最大适应值空间距离的一半作为给定距离。

c) 用每代的最优个体和种群中的所有个体进行交叉,使最优个体的优良基因在种群内迅速扩散。这种交叉方式符合生物学领域内良种繁殖理

论,它能保证最优个体的最优基因得到保留,并在整个种群中得以继承。

d) 采用第 1 个变异算子的目的在于:当两个个体的距离太近时,交叉算子所能产生的作用会减弱,而这时采用对 1 个个体变异,可以使得算法在最优个体的邻域内作更进一步的精确搜索。

e) 采用第 2 个变异算子的目的:处理大搜索空间时,为使算法跳出局部最优解而对种群加一个较小的扰动。单纯地采用一个微小的变异算子,可能无法保证算法跳出局部最优解,尤其当局部最优解是当前精英个体时,其基因会迅速遍布整个种群,而使种群收敛于这个局部最优解。适当控制第 2 个变异概率,可以在算法趋于收敛时对其加以扰动,这种方法在处理多峰、多维,大搜索空间时很有效。因此,采用第 1 个变异算子可以在当前最优解附近的局部范围内进行“求精”的搜索,采用第 2 个变异算子可以在整个搜索空间内作“求泛”的搜索,从而保证算法能收敛到全局最优解。

f) 将每代的最优个体保存在种群中的第  $N+1$  位,相当于精英保留策略。

g) 没有选择算子,算法自动保持一个稳定的种群。

## 2.3 ScGA-PSO 优化算法

PSO 无需提供任何初始化信息就能在所求问题的解空间中求得最优解,是一新兴的全局优化方法,但对于一些复杂问题,存在容易陷入局部极值的缺陷。从 ScGA 的算法特点来看,由于放弃了选择算子,使得算法能够保持一个稳定的种群,这种特点能够和 PSO 算法相匹配。针对 PSO 优化算法对于复杂问题容易陷入局部极值的缺陷,ScGA 的交叉算子和特有的两个变异算子能够帮助 PSO 优化算法扩大搜索空间,并能通过变异算子对陷入极值的粒子产生小的扰动,使其脱离局部极值;而 PSO 算法收敛的快速性又可以帮助 ScGA 更快更好地收敛到最优值。可以发现 PSO 优化算法和 ScGA 优化算法的特点存在互补性,因此将这两者结合形成的新的算法可以提供更加优秀的函数优化性能。

ScGA-PSO 算法将 PSO 算法和 ScGA 做并行处理,即两者各自的函数优化过程相互并行不干扰,但是在优化完成之后,相互交换各自种群中最好的  $P$  个个体, $P$  的个数视实际情况而定。这样即保持了这两种算法的各自的优势和独立性,又能较有效地避免陷入局部极值当中。

## 2.4 算法流程

ScGA-PSO 混合算法分为 6 个基本流程。

Step1: 初始化 ScGA-PSO 的参数; Step2: 对两个独立种群的每个粒子的状态进行初始化, 计算对应的适应值, 并保存每个粒子的个体最优位置、分群的最优位置与全局的最优位置, 及其对应的适应值; Step3: 进行相应的 PSO 优化计算以及 ScGA 的交叉, 第一、第二变异的计算; Step4: 对全局的最优值以及全局最优位置进行更迭, 并更新各自种群个体的最优位置; Step5: 交换两个独立种群的  $P$  个最优个体; Step6: 如果停止条件未满足, 转 Step3, 否则停止迭代, 输出全局最优解。

3 测试函数的优化和结果讨论

3.1 测试函数简介

3.1.1 Rosenbrock 函数(讨论二元情况)

$$\min f(x_1, x_2) = 100(x_1^2 - x_2)^2 + (1 - x_1)^2$$
$$- 2.048 \leq x_1, x_2 \leq 2.048$$

(6)

这个函数只在 (1, 1) 处收敛至惟一的全局最小值, 全局最大值为 0。这是一个常见的多峰值优化函数。

3.1.2 F2 函数(考虑二元的情况)

$$\max f(x_1, x_2) = \frac{\sin(\sqrt{(x_1 - 50)^2 + (x_2 - 50)^2} + e)}{\sqrt{(x_1 - 50)^2 + (x_2 - 50)^2} + e} + 1$$
$$- 100 \leq x_1, x_2 \leq 100$$

(7)

该函数也是多峰值优化函数, 只在全局 (50, 50) 处取得最大值 1.151 1。

3.1.3 Schaffer F6 函数

$$\max f(x_1, x_2) = 0.5 - \frac{(\sin\sqrt{x_1^2 + x_2^2})^2 - 0.5}{(1 + 0.001(x_1^2 + x_2^2))^2}$$
$$- 10 \leq x_1, x_2 \leq 10$$

(8)

该函数也是很难的多峰值优化函数, 它有无数个极大值点, 其中只有在 (0, 0) 处取得全局最大值, 最大值为 1。

3.2 测试结果与分析

文中同时使用 ScGA-PSO 混合算法和 PSO 对上述测试函数进行优化。最大迭代次数均为 2 000 代。惯性权值都是按照余弦规律由 1.8 衰减到 0.02。加速系数  $c_1$  和  $c_2$  均取 2。PSO 算法的粒子的个数为 40 个。ScGA-PSO 混合算法中 PSO 算法部分的粒子个数为 40 个, ScGA 算法部分的种群规模为 40 个。ScGA 算法中的交叉概率为 0.77, 第一变异算子的变异概率为 0.003, 第二变异算子的变异概率为 0.001。算法采用实数编码。

由于 ScGA-PSO 混合算法和 PSO 都是随机

搜索算法, 单凭一两次搜索的结果难以说明搜索的有效性。从概率角度来对比算法的有效性, 优化时分别用各算法对每一测试函数进行 100 次独立测试, 并进行统计汇总, 测试结果的统计汇总对比见表 1 所列。

表 1 测试函数优化结果

Test functions	ScGA-PSO			PSO		
	Success rate, %	Optimal fitness	Mean steps	Success rate, %	Optimal fitness	Mean steps
Rosenbrock	100	0	1 427	95	0	1 935
F2	58	1.151 1	1 327	6	1.151 1	1 976
Schaffer F6	91	1	1 049	68	1	1 758

由表 1 可知, 在算法参数等同的情况下, ScGA-PSO 混合算法寻优时获得全局最优解的概率明显高于 PSO 算法寻优时获得全局最优解的概率, 并且收敛速度明显加快。而且, 在测试过程中发现, PSO 算法容易陷入局部极值点, 而且一旦陷入就很难跳出局部最优。特别明显的就是在 F2 函数中, PSO 算法极其容易陷入局部极大值 1.128 4, 而 ScGA-PSO 混合算法则比较好地收敛到全局最大值 1.151 1。以上数据表明了 ScGA-PSO 混合算法由于加入了 ScGA 算法, 相比于 PSO 算法, ScGA-PSO 混合算法的性能明显更加优秀。

4 ScGA-PSO 算法在延迟焦化装置分馏塔汽油干点软测量模型中的应用

炼油厂的延迟焦化装置是以贫轻的重质油(减压渣油)为原料, 在高温(约 500 ℃ 左右)下进行热裂化和缩合反应, 生成气体、汽油、柴油、蜡油和焦炭, 采用成熟的延迟焦化工艺, 将焦化油(减压渣油和循环油)经加热炉加热迅速升温至焦化反应温度, 进入焦炭塔进行焦化反应, 生成的焦炭留于塔内, 生成的油气从塔顶出来进入分馏塔进一步分离。其核心设备是加热炉、焦炭塔和分馏塔。从焦炭塔顶逸出的油气和蒸气等混合物进入分馏塔与原料油换热后, 脱去部分循环油, 而大量的油气则继续上升, 在分馏塔中进行传热传质, 分割出汽油、柴油和蜡油。

4.1 辅助变量选择

影响粗汽油干点的因素很多, 对于辅助变量的选择, 除了解整个延迟焦化装置与工艺过程和分析分馏原理与过程外, 还要结合现场工艺员及控制员的实践经验, 并结合其灵敏性、特异性, 选取这些参数作为影响粗汽油干点软测量的辅助变量: PI-

1122——塔顶压力, kPa; TI-31——分馏塔顶温度, ℃; TI-1181——中段回流温度, ℃; TI-34——中段回流抽出温度, ℃; FIC-1107——顶回流流量, t/h; FIC-1103——中断回流量, t/h; TI-1186——顶回流温度, ℃; TI-13——塔底进料温度 1, ℃; TI-14——塔底进料温度 2, ℃。

4.2 利用神经网络建立软测量模型

选择了以上 9 个辅助变量, 建立一个有 9 个输入、10 个中间层、1 个输出的 9-10-1 的神经网络, 作为所使用的软测量模型。神经网络的传递函数均为双曲正切函数, 其目标函数:

$$\min E = \sum (t - y)^2$$

式中  $t$ ——粗汽油干点的实际化验值;  $y$ ——粗汽油干点模型计算值。

在将采集的数据根据  $3\sigma$  准则剔除异常数据, 再进行平滑、归一化处理后, 将得到的 287 组数据分为两份, 其中的 237 组数据用于神经网络训练。在使用 ScGA-PSO 算法进行训练后, 得出的训练样本均差为 0.386 6, 绝对误差的平均值为 0.289 9。没参加训练的 50 组数据作为检验样本对所建模型进行检验, 检验样本的均方差为 0.459 9, 绝对误差的平均值为 0.367 0。所有的样本数据中, 有 86% 的样本数据的误差绝对值小于 1, 100% 的样本数据的误差绝对值小于 2。这些数据表明, 所建模型的预测值与实际化验值的拟合程度比较好, 该模型能较好地预测粗汽油干点值。实际值与预测值的对比结果如图 1 所示。




图 1 ScGA-PSOBPNN 的实际值与预测值对比

采用同样的数据, 使用 PSO 训练神经网络, 构建出粒子群神经网络 (PSOBPNN) 的粗汽油干点值软测量模型, 不如 ScGA-PSO 模型得到的结果好。它的检验样本的均方差与绝对误差的平均值都比 ScGA-PSOBPNN 的高, 所有样本数据中也只有 68% 的样本误差小于 1, 94% 的样本误差小于 2。这表明 ScGA-PSO 模型相比 PSOBPNN 的测量精度有了一定的提高。具体对比见表 2 所列。

表 2 ScGA-PSOBPNN 模型与 PSOBPNN 模型比较

	ScGA-PSOBPNN 模型	PSOBPNN 模型
MSE of training sample	0.391 3	1.081 1
MAE of training sample	0.302 6	0.589 9
MSE of test sample	0.388 8	0.778 5
MAE of test sample	0.284 5	0.617 6

5 结束语

文中提出的 ScGA-PSO 混合算法相比 PSO 算法而言, 能够比较好地克服 PSO 算法容易陷入局部极值的缺点。通过函数优化的测试可以发现, ScGA-PSO 混合算法在优化速度和优化精度方面都有了较大的提高, 并且基于 ScGA-PSO 混合算法建立的神经网络软测量模型也有很好的表现。ScGA-PSO 混合算法为 PSO 算法的改进提供了一条新的思路与方法。

参考文献:

1 KENNEDY J, EBERHART R C. Particle Swarm Optimization [C] // Proc IEEE Int. Conf. on Neural Networks. Perth. WA, Australia, 1995: 1942-1948

2 EBERHART R C, KENNEDY J. A New Optimizer Using Particle Swarm Theory [C] // Proc. the Sixth Int. Symposium on Micro Machine and Human Science. Nagoya Japan, 1995: 39-43

3 EBERHART R C, SHI Y. Particle Swarm Optimization: Developments, Applications and Resources [C] // Proc. 2001 Congress on Evolutionary Computation. Seoul South Korea, 2001: 81-86

4 PARASOPOULOS K E, M. N. Vrahatis Recent Approaches to Global Optimization Problems through Particle Swarm Optimization [Z]. Natural Computing 1: 235 - 306, 2002, Netherlands: Kluwer Academic Publishers. Printed in the Netherlands

5 关志华, 寇纪淞, 李敏强. 一种改进的遗传算法 Scatter GA [J]. 控制与决策, 2002, 17, (5): 579 - 582